

已登记模型

10

所有版本均为 v1 / READY

最佳 Held-out Macro-F1

75.1%

DeepSeek 24-shot · n=960


最佳本地 CV Macro-F1

64.7%

TF-IDF Combined + Balanced


Held-out 最终测试

同一 960 条测试集，可直接比较



本地与冻结向量实验排名

5-fold CV / OOF · 训练分区 n=3,838




结论

DeepSeek 的 Macro-F1 高 11.3 个百分点，少数类提升尤其明显。
若追求最高效果：DeepSeek；若追求免费、低延迟、离线部署：Production。
DeepSeek 依赖外部 API、网络可用性和按量费用。

冻结 RobBERT 未超过 TF-IDF；LinearSVC 接近，但仍低约 1.5 个百分点。

少数类 Negative F1

Negative 训练样本仅 240 / 3,838 ; Held-out 与 OOF 口径分开展示



全部 Registered Models

版本均为 v1 · READY · 主指标为 Macro-F1

模型	评估	部署	主指标	定位
sentiment-deepseek-v4-flash-24shot	Held-out	外部 API	75.1%	实验 / 最佳效果
sentiment-combined-balanced	CV	本地 CPU	64.7%	最佳本地 CV
sentiment-combined-balanced-masked	CV	本地 CPU	64.6%	候选
sentiment-production	Held-out	本地 CPU	63.8%	推荐本地部署
sentiment-linear-svc	CV / OOF	本地 CPU	63.2%	实验 / 未提升
sentiment-frozen-robbert-embeddings	CV / OOF	HF + CPU	51.7%	实验 / 未提升
sentiment-combined-logreg	CV	本地 CPU	49.2%	基线候选
sentiment-char-logreg	CV	本地 CPU	47.2%	基线候选
sentiment-word-logreg	CV	本地 CPU	44.7%	基线候选
sentiment-dummy-prior	CV	本地 CPU	21.3%	最低基线

阅读说明

Held-out 是最终测试；CV / OOF 用于训练阶段选择。两种口径不能用微小差距直接判定胜负。Production 与 Combined + Balanced 属于同一模型路线，但分别展示最终测试与交叉验证结果。